CS341-TuamYang — Current Data Architecture

สถานะ ณ Checkpoint 12 พ.ย. 2569 · deploy จริงบน AWS ด้วย SAM + GitHub Actions

GH — CI/CD · GitHub Actions + AWS SAM (D3)
PR → ci (tests · cfn-lint · sam build) → merge main → cd-prod: approve (env production) → OIDC role → sam deploy tuamyang-prod

PUBLIC DATA SOURCES

ไม่ต้องใช้ API key แต่ไม่มีเอกสารทางการ → เก็บ raw ทุกครั้งที่ดึง

ThaiWater API · สสน.
ระดับน้ำ + ตลิ่ง: 8 สถานี
ทุก 10 นาที (ช้า ~10–15 นาที)
ฝน: 134 สถานี

Traffy Fondue API
รายงานร้องเรียน + พิกัด
ย้อนหลังถึงกลางปี 2565
≤1,000 เรื่อง/ครั้ง, เวลา UTC

ขอบเขตแขวง · กรมแผนที่ทหาร
ไฟล์ Shapefile (ผ่าน HDX)
โหลดครั้งเดียว

AWS Cloud · prod account · ap-southeast-1 · stack tuamyang-prod (dev = Learner Lab ใช้ template เดียวกัน)

EB — EventBridge (D1)
schedule 3 rules
15 นาที · 1 ชม. · 01:15

(1)

λ — AWS Lambda
Python 3.12

`ingest-thaiwater`
ระดับน้ำ ทุก 15 นาที (8 สถานี)
ฝน ทุก 1 ชม. (series 24 ชม.)

`ingest-traffy`
รายวัน 01:15 (วันที่ปิดแล้ว)
รายชั่วโมง: ปิดไว้ เปิดช่วงฝนหนัก

`load_boundaries`
ยังไม่ deploy · spatial join (#3)

(2)

S3 — Amazon S3
tuamyang-prod-data-<account>

- `incoming/` envelope JSON 1 ไฟล์/batch → trigger
  `thaiwater/dt=…/hour=…/`
  `traffy/dt=…/`
- `raw/` ต้นฉบับ ไม่แก้ ไม่ลบ
- `checkpoints/ · staged/` manifest Traffy · สถานะ backfill
- `quarantine/` batch ที่ FAIL + validation report
- `trusted/` JSONL 1 แถว/บรรทัด · ผ่านการตรวจ
  `waterlevel · rain · traffy`
- `processed/` report · _SUCCESS / _QUARANTINED
- `curated/` khwaeng_hourly · ยังสร้างบนเครื่อง (D2)

EB (3) rule: Object Created incoming/*

SF — AWS Step Functions
tuamyang-prod-pipeline · Lambda pipeline-step ตัวเดียวทุก state

`CheckBatch`
key → batch_id · มี marker → Skipped
Traffy: รอ manifest SUCCESS (retry)

`ValidateBatch`
22+ กติกา: schema • key ซ้ำ • ตลิ่งตรง ref • ความสด ≤1 ชม. • ฝน ≥ 0 • hash Traffy
→ PASS / WARN / FAIL

FAIL → (4) → quarantine/ + _QUARANTINED.json

ผ่าน?

PASS / WARN → (5) → trusted/ JSONL + _SUCCESS.json

`TransformBatch`
envelope → JSONL ลง trusted/
ฝน: แตก series เป็นรายชั่วโมง
ติด validation_flags รายสถานี

`PublishBatch`
เขียน _SUCCESS.json (row_count, warnings) = idempotency marker

`VerifyBatch`
อ่านกลับ: row count + batch_id ตรง
→ Published (prod: ~2.6 วินาที/batch)

AT — Glue + Athena
DDL/SQL พร้อมใน sql/
ยังไม่ deploy (Phase 3)

PY — Curated builder
trusted/ → khwaeng_hourly
รันบนเครื่อง ยังไม่ขึ้น AWS

(6)

DATA PRODUCTS

คำตอบ Q1–Q2 (เบื้องต้น)
เดส 24–26 ก.ย. · evidence/curated

Data quality report
validation_report ทุก batch + DQ ของตาราง curated

แผนที่ความเสี่ยงรายแขวง
รอ spatial join (#3)

คำแนะนำรายตำแหน่ง
หลัง checkpoint

---

(1) EventBridge schedule เรียก Lambda ตามรอบ
(2) Lambda เขียน envelope ลง incoming/ + raw/
(3) Object Created → rule เริ่ม state machine
(4) FAIL → quarantine/ + _QUARANTINED.json
(5) PASS/WARN → trusted/ JSONL + _SUCCESS.json
(6) trusted/ → curated + SQL → data products

——— deploy และรันบน prod แล้ว
– – – ยังไม่ deploy / รันบนเครื่อง

D1 batch ตามรอบ แทน streaming
D2 รวมข้อมูลที่ระดับ แขวง × ชั่วโมง
D3 IaC (SAM) + OIDC · ไม่มี ClickOps / key ถาวร